



Engenharia de Software e Engenharia Mecânica

Projeto Prático: Comitê de Classificadores

Gabrielly Gomes de Oliveira	825160672
Kauã Sanches de Souza Ferreira	825154278
Kauê Victor Faria de Jesus	825135270
Matheus De Barros Pinto	825139347
Thamires Parreira Ribeiro	825110946

São Paulo

Junho/2026

Comitê de Classificadores

Gabrielly Gomes de Oliveira	825160672
Kauã Sanches de Souza Ferreira	825154278
Kauê Victor Faria de Jesus	825135270
Matheus De Barros Pinto	825139347
Thamires Parreira Ribeiro	825110946

Relatório apresentado à disciplina de Inteligencia Artificial como parte da avaliação parcial.

Professor: Rodrigo Bossini
Universidade São Judas Tadeu

1. INTRODUÇÃO

A Inteligência Artificial (IA) tem se consolidado como uma das principais ferramentas para análise e interpretação de grandes volumes de dados, permitindo identificar padrões complexos, gerar previsões e auxiliar na tomada de decisões estratégicas. No cenário contemporâneo da análise esportiva, técnicas de Aprendizado de Máquina (Machine Learning) têm sido amplamente incorporadas para compreender de forma profunda o comportamento de atletas e equipes durante as competições.

No contexto da National Football League (NFL), sistemas avançados de rastreamento coletam continuamente coordenadas posicionais e métricas físicas instantâneas dos jogadores em campo. Esses dados incluem variáveis de alta fidelidade como posicionamento bidimensional, velocidade escalar e aceleração instantânea.

Diante desse cenário, este projeto teve como objetivo desenvolver um sistema de classificação supervisionada capaz de identificar automaticamente se o registro cinemático de uma jogada pertence ou não a uma determinada região de interesse (segmentada por um limiar numérico pré-estabelecido). Para otimizar a confiabilidade e robustez das previsões, implementou-se um Comitê de Classificadores baseado em Ensemble Learning, combinando múltiplos modelos preditivos de naturezas matemáticas distintas. O trabalho abrange desde as etapas fundamentais de pré-processamento até a validação estatística rigorosa por matriz de confusão.

2. DESCRIÇÃO DA BASE DE DADOS

A base de dados utilizada neste projeto provém do arquivo de telemetria input_2023_w12.csv, que reúne dados brutos de rastreamento de atletas da NFL durante partidas oficiais. Cada linha do dataset representa o estado cinemático instantâneo de um jogador em um frame específico da jogada.

O carregamento, manipulação inicial e estruturação lógica da base foram executados em ambiente Python, utilizando a biblioteca Pandas para gerenciamento de DataFrames:

```
from google.colab import files
files.upload()

import pandas as pd
df = pd.read_csv('input_2023_w12.csv')
df.head(294942)
```

Para a modelagem preditiva, selecionou-se um espaço de atributos (features) composto por quatro variáveis independentes altamente representativas da dinâmica espaço-temporal do jogo, descritas na Tabela 1.

Tabela 1 – Atributos selecionados para a modelagem preditiva

Variável	Descrição
x	Posição horizontal do jogador no plano bidimensional do campo.
y	Posição vertical do jogador no plano bidimensional do campo.
s	Velocidade instantânea do jogador (m/s ou unidades equivalentes de rastreamento).
a	Aceleração instantânea do jogador (m/s ²).

3. DEFINIÇÃO DO PROBLEMA (TARGET)

O problema foi estruturado sob o paradigma clássico de classificação binária supervisionada. O objetivo central é mapear de forma inteligível as variáveis de entrada preditoras (x, y, s, a) para inferir uma variável alvo categórica e binária denominada red_zone_play.

A variável target foi sintetizada por meio da aplicação de um limiar condicional booleano sobre a métrica de posicionamento absoluto da linha de jarda original contida na base primária:

```
df['red_zone_play'] = (  
    df['absolute_yardline_number'] > 80  
) .astype(int)
```

É imperativo salientar que o valor escalar 80 adota uma função puramente matemática de segmentação lógica dentro do espaço amostral disponível, não se vinculando de forma estrita à unidade física regulamentar do esporte. Essa transformação resultou em duas classes mutuamente exclusivas e bem definidas:

- **Classe 0:** Registro fora da região crítica de interesse delimitada pelo critério numérico.
- **Classe 1:** Registro dentro da região crítica de interesse delimitada pelo critério numérico.

4. PRÉ-PROCESSAMENTO DOS DADOS

Para assegurar a consistência matemática e mitigar vieses indesejados durante a convergência dos algoritmos, os dados brutos passaram por um fluxo sistemático de tratamento. O primeiro passo consistiu na imputação de dados ausentes (missing values), onde as lacunas foram preenchidas de forma homogênea utilizando a média aritmética calculada a partir das colunas numéricas correspondentes:

```
df = df.fillna(df.mean(numeric_only=True))
```

Na sequência, isolou-se a matriz de atributos de entrada (X) e o vetor coluna associado à variável resposta (y):

```
X = df[['x', 'y', 's', 'a']]  
y = df['red_zone_play']
```

Por fim, aplicando o princípio metodológico da validação cruzada retida (holdout methodology), o conjunto de dados foi devidamente particionado na proporção clássica de 80% para treinamento e 20% para teste, blindando a avaliação contra o sobreajuste (overfitting) e permitindo validar a real capacidade de generalização do sistema frente a dados inéditos:

```
from sklearn.model_selection import train_test_split  
  
X_treino, X_teste, y_treino, y_teste = train_test_split(  
    X,  
    y,  
    test_size=0.2  
)
```

5. MODELAGEM DOS CLASSIFICADORES

A estratégia experimental consistiu em treinar e parametrizar inicialmente três arquiteturas de aprendizado supervisionado de naturezas matemáticas e premissas fundamentalmente distintas, permitindo uma análise comparativa e rica de desempenho individual.


5.1 K-Nearest Neighbors (KNN)

O KNN é um algoritmo não-paramétrico baseado em instâncias que realiza a classificação estimando a proximidade geométrica no espaço hiperdimensional de atributos. Para cada nova instância de teste, o modelo computa as distâncias euclidianas em relação às instâncias de treino, atribuindo a classe majoritária identificada entre os k vizinhos mais próximos.

```
from sklearn.neighbors import KNeighborsClassifier

knn = KNeighborsClassifier()

knn.fit(X_treino, y_treino)
```

A screenshot of a Jupyter Notebook interface. The top part shows a code cell with three lines of Python code: 'from sklearn.neighbors import KNeighborsClassifier', 'knn = KNeighborsClassifier()', and 'knn.fit(X_treino, y_treino)'. Below the code cell, there is a dropdown menu for the 'KNeighborsClassifier' class, which is currently expanded to show the constructor 'KNeighborsClassifier()'. The dropdown menu also includes a small 'i' icon and a question mark icon.


5.2 Árvore de Decisão

Este modelo constrói uma estrutura hierárquica de decisão baseada em divisões sucessivas (splits) dos dados. Utilizando critérios matemáticos de pureza e ganho de informação (como o Índice Gini ou Entropia), o algoritmo estabelece regras lógicas condicionais sobre as features, oferecendo excelente interpretabilidade.

```
from sklearn.tree import DecisionTreeClassifier

arvore = DecisionTreeClassifier()

arvore.fit(X_treino, y_treino)
```

A screenshot of a Jupyter Notebook interface. The top part shows a code cell with three lines of Python code: 'from sklearn.tree import DecisionTreeClassifier', 'arvore = DecisionTreeClassifier()', and 'arvore.fit(X_treino, y_treino)'. Below the code cell, there is a dropdown menu for the 'DecisionTreeClassifier' class, which is currently expanded to show the constructor 'DecisionTreeClassifier()'. The dropdown menu also includes a small 'i' icon and a question mark icon.

5.3 Gaussian Naive Bayes

Baseado no célebre Teorema de Bayes, este classificador probabilisticamente rígido assume a premissa de independência condicional mútua entre todos os atributos preditores (daí a alcunha naive). A variação Gaussiana especificamente modela a distribuição de probabilidade das variáveis contínuas sob a premissa de uma distribuição normal (Gaussiana).

```
from sklearn.naive_bayes import GaussianNB

bayes = GaussianNB()

bayes.fit(X_treino, y_treino)
```

▼ GaussianNB ⓘ ?

GaussianNB()

6. CONSTRUÇÃO DO COMITÊ DE CLASSIFICADORES


Com o intuito de mitigar vieses idiossincráticos de cada arquitetura isolada e elevar os níveis de robustez global, foi desenvolvido um Comitê de Classificadores estruturado sob os preceitos modernos de Ensemble Learning. A combinação estratégica de múltiplos preditores visa balancear e contrapor falhas individuais, originando uma fronteira de decisão coletiva estável.

A fusão das forças preditivas do KNN, Árvore de Decisão e Gaussian Naive Bayes foi operada por meio da classe meta-estimadora VotingClassifier:

```
from sklearn.ensemble import VotingClassifier

comite = VotingClassifier(
    estimators=[
        ('knn', knn),
        ('arvore', arvore),
        ('bayes', bayes)
    ],
    voting='soft')

comite.fit(X_treino, y_treino)
```



O diagrama ilustra a estrutura interna de um `VotingClassifier`. No topo, o título `VotingClassifier` é exibido. Abaixo dele, há três seções principais: `knn`, `arvore` e `bayes`. Cada seção contém um botão de seta para a direita seguido pelo nome do classificador: `KNeighborsClassifier`, `DecisionTreeClassifier` e `GaussianNB`, respectivamente. Cada botão também possui um ícone de ajuda (uma seta dentro de um círculo). Linhas de conexão desce de cada um dos três classificadores e se reúnem no fundo, representando a fusão dos resultados.

Adotou-se expressamente a abordagem de Soft Voting. Diferente do Hard Voting (que computa apenas a maioria simples dos votos categóricos), o Soft Voting calcula a média aritmética das probabilidades a posteriori estimadas para cada classe por cada algoritmo do comitê. A classe final predita é aquela que obtém a maior probabilidade média ponderada, mecanismo que confere um peso naturalmente superior a modelos que manifestam alto grau de certeza em suas predições.

7. RESULTADOS E MÉTRICAS DE AVALIAÇÃO

Para quantificar e comparar empiricamente a performance do comitê integrado vis-à-vis os classificadores de base, extraíram-se métricas estatísticas consagradas sobre o conjunto de testes retido, conforme o bloco de execução abaixo:

```
from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score

for nome, modelo in modelos.items():
    predicoes = modelo.predict(X_teste)
    accuracy = accuracy_score(y_teste, predicoes) * 100
    precision = precision_score(y_teste, predicoes) * 100
    recall = recall_score(y_teste, predicoes) * 100
    f1 = f1_score(y_teste, predicoes) * 100
```

A partir da Matriz de Confusão gerada pelo Comitê (detalhada na Seção 8), foram computados os valores exatos de Verdadeiros Positivos (VP = 11.293), Verdadeiros Negativos (VN = 43.485), Falsos Positivos (FP = 1.973) e Falsos Negativos (FN = 2.237), totalizando 58.988 instâncias de validação.

Acurácia (Accuracy):

Mede a proporção global de acertos sobre o total de registros analisados. O Comitê alcançou o patamar de 92,86%, confirmando uma altíssima eficácia preditiva agregada.

Precisão (Precision):

Indica a taxa de acerto real dentro do universo de predições que o modelo apontou como positivas (Classe 1). O índice de 85,13% atesta que o comitê gera poucos alarmes falsos (Falsos Positivos).

Recall (Sensibilidade):

Mede a capacidade do comitê em capturar os casos reais que verdadeiramente pertencem à Classe 1. O resultado de 83,47% indica que o modelo recupera a ampla maioria das jogadas de interesse.

F1-Score:

Consiste na média harmônica balanceada entre a Precisão e o Recall, servindo como o indicador mais confiável para problemas com leve desbalanceamento de classes. O patamar de 84,29% consolida o sucesso da modelagem.

8. MATRIZ DE CONFUSÃO

A Matriz de Confusão do Comitê de Classificadores permite inspecionar de forma absoluta a distribuição fina dos acertos e desvios cometidos pela abordagem integrada, conforme exposto na Tabela 2.

Tabela 2 – Matriz de confusão absoluta do Comitê de Classificadores (Soft Voting)

	Predito: Classe 0	Predito: Classe 1
Real: Classe 0	43.485 (Verdadeiro Negativo)	1.973 (Falso Positivo)
Real: Classe 1	2.237 (Falso Negativo)	11.293 (Verdadeiro Positivo)

Fonte: Dados obtidos experimentalmente pelo autor (2026).

A análise da Tabela 2 indica que o comitê manteve um comportamento simétrico de erros, com 1.973 Falsos Positivos e 2.237 Falsos Negativos, um equilíbrio altamente desejável que chancela a robustez do Soft Voting diante das variações cinemáticas.

9. DISCUSSÃO

Os resultados práticos colhidos ao longo dos testes validam empiricamente a premissa de que os atributos espaciais e dinâmicos de rastreamento (x , y , s , a) guardam correlações estatísticas intrínsecas profundas, capazes de caracterizar e isolar padrões complexos de jogadas na NFL. O limiar operacional adotado atuou como um elemento demarcador eficiente para aferir as capacidades adaptativas dos algoritmos.

A engenharia do Comitê de Classificadores desempenhou seu papel principal com sucesso: ao unificar modelos com fundamentos distintos (geométricos no KNN, estruturais/lógicos na Árvore de Decisão e probabilísticos no Naive Bayes), o Ensemble conseguiu neutralizar as fraquezas preditivas individuais de cada técnica. O Soft Voting provou ser superior por ponderar a incerteza das predições através de suas probabilidades probabilísticas, gerando uma fronteira de decisão final suave, resiliente e de alta confiabilidade.

10. CONCLUSÃO

Este projeto cumpriu integralmente o objetivo proposto de projetar e validar um sistema de Inteligência Artificial voltado à classificação automatizada de registros cinemáticos da NFL com base em telemetria real de atletas.

O fluxo metodológico percorrido — integrando a ingestão de dados, tratamento de nulidades, engenharia de target, particionamento em holdout, treinamento distribuído e consolidação via comitê — culminou em uma solução robusta para a Engenharia de Software aplicada. As marcas obtidas (Acurácia de 92,86% e F1-Score de 84,29%) solidificam o valor prático do modelo. Em última análise, este trabalho evidencia o imenso potencial adaptativo do Aprendizado de Máquina em converter massas complexas de dados esportivos brutos em inteligência tática acionável, abrindo caminhos para sistemas preditivos de alto desempenho.